

决策树的基本流程:

输入: 数据集 D , 属性集 $A = \{a_1, \dots, a_d\}$
 $D = \{a_1, u_1, \dots, a_m, y_m\}$
过程: TreeGenerate(D, A)
1: 生成结点 node;
2: if D 中样本全属于同一类别 C then
3: 将 node 标记为 C 类叶结点 return
4: end if
5: if $A = \emptyset$ or D 中样本在 A 中所属属性上取值相同 then
6: 将 node 标记为叶结点, 其类别标记为 D 中样本数最多类; then
7: end if
8: 从 A 中选取最优属性 a_k :
for a_k 中每一个值 a_k^v do:
为 node 生成一个分支, 表示 D 在 a_k 上取值为 a_k^v 的集 D^v
if D^v 为空 then
将分支标记为叶结点
else
以 TreeGenerate($D^v, A \setminus \{a_k\}$) 为分支结点.
end if
end for
很明显这是一个递归的程序, 有3种情况会结束返回: ①数据集同一类别 ② D 中样本在 A 上取值全一样或者 A 中已空 ③数据集为空

知道怎么选 a_k 之后, 再来防止过拟合, 决策树对过拟合的手段为剪枝处理

剪枝: 按类别划分前进行评价, 若划分后泛化性能提升, 则无需划分
后剪枝: 先生成完整的决策树, 自后而上

需要验证某

④ 预剪枝: 有一种特殊情况, 仅有一层的决策树, 称为决策树正

预剪枝: 有欠拟合风险, 有可能划分后再划分会更好

后剪枝: 有欠拟合风险, 泛化性能优于预剪枝, 但开销大

连续与缺失处理

①连续值处理:
连续属性离散化
假设 a 在 D 上出现了 n 个不同取值
将这些值从小到大排序, 记为 $\{a_1, \dots, a_n\}$. 基于划分点 t 可将 D 分为 D_t^-, D_t^+
由于对相邻属性取值 a_i 与 a_{i+1} , t 在区间 $[a_i, a_{i+1})$ 中取任意值结果都一样
 $Ta = \{ \frac{a_i + a_{i+1}}{2} \mid 1 \leq i \leq n-1 \}$ 会产生 $n-1$ 个可能划分点
则 $Gain(D, a) = \max_{t \in Ta} Gain(D, a, t)$
 $= \max_{t \in Ta} Ent(D) - \sum_{x \in D^-, D^+} \frac{|D^v|}{|D|} Ent(D^v)$ [按照 t 分之后, 只产生两种可能]

与离散属性不同, 连续属性可以重复作为划分属性

②缺失值处理:
面对两问题: A. a 在属性值缺失时进行划分属性选择
B. 指定划分属性若样本在该属性上有缺失该怎么办

给定训练集 D 和属性 a , 令 S 表示 D 中在属性 a 上没有缺失值的样本结果

对于问题 A 只需在 S 中判断 a 的优劣即可

假设属性 a 有 V 个取值 $\{a^1, a^2, \dots, a^V\}$, 令 D^v 表示 S 中 a 取值为 a^v 的集合

D^v 表示 S 中属于第 k 类 $\{k=1, 2, \dots, |V|\}$ 的样本子集

有 $D = \bigcup_{k=1}^V D^v$; $S = \bigcup_{k=1}^V D^k$, 假设每个为每个样本 x 赋予一个权重 w_x , 并定义

$p = \frac{\sum_{x \in D} w_x}{\sum_{x \in D} w_x}$ 则有 $\tilde{p}_k = \frac{\sum_{x \in D^k} w_x}{\sum_{x \in D} w_x}$; $\tilde{p}_v = \frac{\sum_{x \in D^v} w_x}{\sum_{x \in D} w_x}$

$\sum_{k=1}^V \tilde{p}_k = 1$; $\sum_{v=1}^V \tilde{p}_v = 1$

$Gain(D, a) = p \times Gain(S, a)$

$= p [Ent(S) - \sum_{v=1}^V \tilde{p}_v Ent(D^v)]$ (之间的情况是每 w_x 都为1)

$Ent(S) = -\sum_{k=1}^V \tilde{p}_k \log_2 \tilde{p}_k$

解决3问题A 则需解决问题B

夜需将来样本划入每个子结点中, 不过权重需要改变, 改变成 $\tilde{p}_v \cdot w_x$; (根据理解, x 的 a 取值其实有非零大的类别和最多的那个 a^v 一样)

划分选择

我的目标是使得划分后的纯度升高

①信息增益:
设当前样本集 D 中第 k 类样本所占比例为 $P_k (k=1, 2, \dots, |V|)$
则 D 的信息熵定义为:
 $Ent(D) = -\sum_{k=1}^V P_k \log_2 P_k$
若 $P_k=0$, 则 $P \log_2 P=0$, $Ent(D)$ 最小值为0, 最大值为 $\log_2 |V|$
假设离散属性 a 有 $\{a_1, \dots, a_V\}$ 种取值, 那么可分成 V 组
每一组都会有 P_k
 $Gain(D, a) = Ent(D) - \sum_{k=1}^V \frac{|D^k|}{|D|} Ent(D^k)$
这就是信息增益

$a_k = \arg \max_{a \in A} Gain(D, a)$

②增益率
由于信息增益对于取值可能多的属性有偏好, 因此引入增益率

$GainRatio(D, a) = \frac{Gain(D, a)}{IV(a)}$

$IV(a) = -\sum_{k=1}^V \frac{|D^k|}{|D|} \log_2 \frac{|D^k|}{|D|}$ (这属性 a 的熵值, a 取值个, $IV(a)$ 个)

$Gain$ 和 $Ratio$ 需结合使用, 先选出 $Gain$ 高于平均水平的 a , 再选出 $Ratio$ max.

③基尼指数
决策树使用基尼指数来划分属性

$Gini(D) = \sum_{k=1}^V P_k P_k = \sum_{k=1}^V P_k (1 - P_k) = \sum_{k=1}^V P_k - \sum_{k=1}^V P_k^2$

$= 1 - \sum_{k=1}^V P_k^2$

V Geni 值实际上反映的是进行一次随机抽样时, 两个样本属于不同类的概率

共有 $|V|$ 类, 抽 $|V|$ 次

很明显, 若样本类别很杂, 那么 $Gini(D)$ 就很小

解释为何信息熵是这样公式

①独立事件的信息量应满足独立性可加, 信息量函数为 I , I 与概率 P 成负相关因为 P 越大, 信息量越小, 比如太阳从东边升起, 几乎没信息量

$I(P(A)) = I(P(A) \cdot I(P(B))$
而 $PCAB) = P(A) \cdot P(B)$
故唯一满足这种规则的函数是 $\log$ 函数

②又因计算机为二进制, 故取 $I(P) = -\log_2 P$

③有 $|V|$ 类, 取基理 $Ent(D) = -\sum_{k=1}^V P_k \log_2 P_k$

若没有求和符号, 则对于二分类问题

$Ent(D) = -P \log_2 P - (1-P) \log_2 (1-P)$

多变量决策树

若将每个属性视为一个坐标轴, 则 d 个属性就构成 d 维空间

每次划分都是沿着坐标轴切一刀, 分类边界由这些刀的分段构成

在学习任务的真实分类边界较复杂时, 需多段划分, 比较麻烦

若自使用斜刀划分, 会简单一些, 这时, 每个非叶结点是

习题

4.1 证明不含冲突数据的训练集, 必存在与训练集一致的决策树

决策树停止两种情况: A. 当前结点属同一类 B. 属性已空 / 所有属性取值一样

A 情况无需多言, 再来一棵一样属性的样本必然落到同样的叶子结点

B 情况在本题情况下可直接归为 A 情况, 无冲突数据, 决策树不会遇见特征相同但标签不同的数据

但是! 这棵树并不好, 这棵树的极限制情况是把每一个样本都分到一叶子结点中, 是过拟合, 需剪枝操作

4.2 试析“使用最小训练误差”作为决策树划分选择准则的缺陷

对于二分类问题, 各指标: ①分类误差: $1 - \max(P, 1-P)$

②信息熵: $-P \log_2 P - (1-P) \log_2 (1-P)$

③基尼指数: $2P(1-P)$

琴生不等式: 对于一个上凸函数, 任意两点 x_1, x_2 有: $\lambda \in [0, 1]$

$f(\lambda x_1 + (1-\lambda)x_2) \geq \lambda f(x_1) + (1-\lambda)f(x_2)$

两边加权平均数 两边加权平均结果

假设当前母结点切成左右两结点: x 是左子结点正例比例 P_{left}

x_2 是右子 $\sim$ P_{right}

权重 λ 是切入左子结点的数据比例 $\frac{|D_L|}{|D|}$

则 $P_{parent} = \lambda P_{left} + (1-\lambda) P_{right}$

母结点正例比例

由于 $Ent(D)$ 是上凸函数

则 $Ent(P_{parent}) \geq \lambda Ent(P_{left}) + (1-\lambda) Ent(P_{right})$

移项后:

$Ent(P_{parent}) - (\lambda \sim) \geq 0$

就是 $Gain$

由于我们的目标是 purity, 而 Ent 与 $Geni$ 都严格满足琴生

不等式的要求, 只要 P_{left} 与 P_{right} 有些微不一样就会导致 $Gain > 0$

而分类误差函数是直线, 若 $P_{left}, P_{right}, P_{parent}$ 在同一侧直线上

就会导致 公式左边 = 公式右边, 计算机就会认为这么分无意义

但实际上可能有一侧的 P 已经远大于 P_{parent} , 即纯度是变大的

但却由于所谓相等导致无法划分

除此之外, 还有异或问题, 如果 $\begin{cases} x_1 = (0, 0) & y = (1) \\ x_2 = (1, 1) & y = (1) \\ x_3 = (0, 1) & y = (0) \\ x_4 = (1, 0) & y = (0) \end{cases}$ 那么两维无法区分, 还是 x_2 分类误差为0, 但实际上再进一步就可以了

总结: ①缺乏严格上凸性, 导致算出增益为0

②空间的异或问题