

课后习题

2026年6月3日 星期三 10:20

6.1. 证明 $d = \frac{w^T x + b}{\|w\|}$

① 先补充一个知识点
对于平面中两点 x_1, x_2
 w 是 w 的法向量
 $w^T x_1 + b - w^T x_2 + b = 0$
则 $w^T (x_1 - x_2) = 0$
 x_1 和 x_2 向量在超平面内部, 可设超平面中任意向量
因此 w 和 $(x_1 - x_2)$ 垂直, w 是平面的法向量
内积是 $\langle a, b \rangle \Rightarrow a^T b$. 因此 w 是法向量而不是 w^T

② 任取一点 x
作垂线 x_0
则 $x - x_0$ 的方向与法向量 w 平行.
即 $x - x_0 = c w$ 因此距离 $d = \|x - x_0\| = |c| \cdot \|w\|$
 $w^T (x - x_0) = c w^T w$
 $w^T x + w^T x_0 = c \|w\|^2$
 $\therefore w^T x + b = c \|w\|^2$
 $\therefore c = \frac{w^T x + b}{\|w\|^2}$
将其代入 r 有: $d = \frac{|w^T x + b|}{\|w\|}$

6.4. 线性判别分析与线性核支持向量机何种条件下等价

LDA 有用条件 $w_{LDA} \propto S_w^{-1} (\mu_1 - \mu_2)$ S_w 为协方差矩阵

KLDA
$$\begin{cases} W_{KLDA} = \arg \max W \\ m_1 = \mu_1^T W = \frac{1}{N_1} \sum_{i \in \text{class 1}} K(C, i) \text{ (相当于求 } \mu_0) \\ m_2 = \mu_2^T W = \frac{1}{N_2} \sum_{i \in \text{class 2}} K(C, i) \end{cases}$$

$d = N^{-1} (C m_1 - m_2)$ $N = K^T K = \sum_{i=1}^2 m_i m_i^T$
(KLDA 是优化 d 再得 W 的)
 $W_{KLDA} = \arg \max W$

SVM: $W_{SVM} = \sum_{i \in \text{class}} d_i \phi(x_i) - \sum_{j \in \text{class}} d_j \phi(x_j)$

对于 KLDA, 若 $N = \lambda K$, 则 $W_{KLDA} = \frac{\arg \max W}{\lambda} \cdot \frac{[\sum_{i \in \text{class 1}} \phi(x_i)]^T [\sum_{j \in \text{class 2}} \phi(x_j)]}{\lambda} (\mu_1^T - \mu_2^T)$
正核核函数
高维 $\rightarrow$ 低维, RBF 核化一次
即有刚性等变性 $PP = P$
 $P \cdot x = x$ (在低维中, 再来一次没用)

$\therefore W_{KLDA} \propto (\mu_1^T - \mu_2^T)$ 且 $W_{LDA} \propto (\mu_1^T - \mu_2^T)$
将 N 拆成 $\Rightarrow \frac{\arg \max W}{\lambda} S_w \arg \max W = \lambda \frac{\arg \max W}{K}$

你这时一定想问 $N = \lambda K$ 本质是啥? 则 $S_w = \lambda I$
说明每一维的 $\Sigma(x, x)$ 相等, 且特征间无相关性

在此基础上再加上旋转不变性, 即可向同分布, 样本云成球形
SVM 的结果才能 $\propto LDA \propto KLDA$

单说 LDA 和 KLDA, 只要 $S_w \propto \lambda I$ 即可

6.5 试述 SVM 与 RBF 神经网络之间的联系 (单输出结果 RBF 与标准二分类的高斯核)

① RBF: $y(x) = \sum_{j=1}^q w_j \exp(-\|x - c_j\|^2) + b$
 C 是隐层神经元的中心点
 w_j 为权重, w_j 为第 j 个隐层神经元的输出
共 q 个隐层

② 高斯核 SVM
 $f(x) = \sum_{i=1}^m d_i y_i K(x_i, x) + b$
 $f(x) = \sum_{i \in SV} d_i y_i \cdot \exp(-\gamma \|x - x_i\|^2) + b$
只有支持向量 $d_i \neq 0$ SV 为支持向量
模型上等价, 但 SVM 优于 RBF, 因为 RBF $\begin{cases} \text{① 需 } \lambda \text{ 调节} \\ \text{② 中心点 } C \text{ 选择? 局部最优} \end{cases}$
SVM $\begin{cases} \text{① 全局最优} \\ \text{② 自带正则化约束} \end{cases}$

6.9 核技巧对率回归, 产生核对率回归

第三章是分成 $\{1, 0\}$ 两类
目标: $\min_{w, b} \frac{1}{2} \|w\|^2 = \sum_{i=1}^M [y_i \ln p_i(x_i) + (1 - y_i) \ln (1 - p_i(x_i))]$
 $y_i = 0 \text{ 或 } 1$ $p_i(x_i) = \frac{1}{1 + \exp(-z_i)}$ $z_i = w^T \phi(x_i) + b$
 $w = \arg \max W$ $\|w\|^2 = w^T w = \alpha^T K \alpha$
 $w^T x_i = \sum_{j=1}^M d_j \phi(x_j)^T \phi(x_i) = \sum_{j=1}^M d_j K(x_j, x_i) = \alpha^T K(C, i)$

则目标函数:
 $\min_{w, b} \frac{1}{2} \alpha^T K \alpha + \sum_{i=1}^M [\ln(1 + \exp(\alpha^T K(C, i) + b)) - y_i (\alpha^T K(C, i) + b)]$
 $\downarrow$
 $Loss_{y_i=1} = \ln(\sim) - (\sim)$
 $Loss_{y_i=0} = \ln(\sim)$

则在 $y_i = 1$ 或 -1
 $y_i = 2y_i - 1$
 $y_i = 1$, $p(x_i)$ 不变 $= \frac{e^z}{1 + e^z} = \frac{1}{1 + e^{-z}} = \frac{1}{1 + e^{-y_i z}}$
当 $y_i = -1$ 时 $p(x_i) = \frac{1}{1 + e^z} = \frac{1}{1 + e^{-y_i z}}$
Loss 统一为: $\sum_{i=1}^M \ln(1 + \exp(-y_i z))$ $z_i = \alpha^T K(C, i) + b$

目标变为: $\min_{\alpha} \frac{1}{2} \alpha^T K \alpha + C \sum_{i=1}^M \ln(1 + \exp(-y_i z_i))$, C 是惩罚因子

$g = K \alpha + \sum_{i=1}^M \frac{1}{1 + \exp(-y_i z_i)}$
 $\frac{\partial g}{\partial \alpha^T} = K + C \sum_{i=1}^M \frac{\partial (1 - p_i)}{\partial z} \cdot (-y_i \cdot K(C, i)) \cdot e^{(-y_i z_i)}$
令 $1 - p_i = \frac{1}{1 + e^z}$ $\frac{\partial (1 - p_i)}{\partial z} = -p_i(1 - p_i)$, 正规的 sigmoid 函数是指数函数, 因此这里产生一个负号

$g = K \alpha + \sum_{i=1}^M C \cdot y_i \cdot (1 - p_i) \cdot K(C, i)$
 $\frac{\partial g}{\partial \alpha^T} = K + C \sum_{i=1}^M y_i \cdot p_i(1 - p_i) \cdot K(C, i) \cdot K^T(C, i) \cdot y_i$
 $= K + C \sum_{i=1}^M p_i(1 - p_i) \cdot K(C, i) \cdot K^T(C, i)$
 $= K + K V K$
 $V = \begin{bmatrix} C \cdot p_1(1 - p_1) & 0 & 0 \\ 0 & \ddots & \\ 0 & 0 & C \cdot p_n(1 - p_n) \end{bmatrix}$

$H = K + K V K$
 $\alpha_{t+1} = \alpha_t - H^{-1} g$