

聚类

形式化：
样本集 $D = \{X_1, \dots, X_m\}$
每个样本 $X_i = (X_{i1}, X_{i2}, \dots)$ n 维
将 D 分成 k 个不相交的簇 $\{C_1, C_2, \dots, C_k\}$ 其中 $C_i \cap C_j = \emptyset$ 且 $D = \bigcup_{i=1}^k C_i$
用 $\lambda_i \in \{1, 2, \dots, k\}$ 表示样本 X_i 的“簇标签”，即 $X_i \in C_{\lambda_i}$
聚类结果可用 m 个元素的簇标记向量 $\lambda = (\lambda_1, \dots, \lambda_m)$ 表示

性能度量

① 簇内相似度和簇间相似度
② 外部指标 (与参考模型相比) 内部指标 (不与 ~)

$D = \{X_1, \dots, X_m\}$ 聚类结果 $C = \{C_1, \dots, C_k\}$
参考模型 $C^* = \{C_1^*, C_2^*, \dots, C_k^*\}$
 λ, λ^* 分别为簇标记向量
 $Q = \{S | S \subseteq \{C_i, X_i\} | \lambda_i = \lambda_i^*, X_i \in \lambda_i^*, i \in S\}$
 $b = \{S | S \subseteq D, SD = \{X_{i \in S}\} | \lambda_i = \lambda_i^*, \lambda_i^* \neq \lambda_i, i \in S\}$
 $c = \{D \setminus S\}$, 则 $D = D \cup c$, 则
 $a+b+c+d = \frac{m(m-1)}{2}$
 $JC = \frac{a}{a+b+c}$ FM = $\frac{a+b}{a+b+c}$
RI = $\frac{a+d}{a+b+c}$ (Rand Index)
= 评价指标均在 $[0, 1]$, 越大越好

$avg(C) = \frac{2}{|C|(|C|-1)} \sum_{1 \leq i < j \leq |C|} dist(x_i, x_j)$
簇内样本间的平均距离
 $diam(C) = \max_{i \in C, j \in C, i \neq j} dist(x_i, x_j)$
簇内样本间距离 max
 $d_{min}(C_i, C_j) = \min_{x_i \in C_i, x_j \in C_j} dist(x_i, x_j)$
 C_i 与 C_j 最近样本距离
 $d_{cen}(C_i, C_j) = dist(\mu_i, \mu_j)$
 C_i 与 C_j 样本中心的距离
 $DBI = \frac{1}{k} \frac{1}{|C|} \max_{i \in C} \left(\frac{avg(C_i) + avg(C)}{d_{cen}(C_i, C_i)} \right)$
 $DI = \min_{1 \leq k \leq K} \left\{ \max_{j \in R} \left(\frac{d_{min}(C_i, C_j)}{\max_{i \in C} diam(C_i)} \right) \right\}$
DBI 越小越好, DI 越大越好

距离计算

$dist(\cdot, \cdot)$ 需满足: ① 非负性 ② 同一性 ③ 对称性 ④ 直连性
 $dist(x_i, x_j) = 0$ 当且仅当 $x_i = x_j$
 $dist(x_i, x_j) \leq dist(x_i, c) + dist(c, x_j)$

闵可夫斯基距离
 $dist_{mk}(x_i, x_j) = \left(\sum_{u=1}^n |x_{iu} - x_{ju}|^p \right)^{\frac{1}{p}}$
 $p=1$, 曼哈顿距离
 $p=2$, 欧氏距离

序“很重要”
 $\{1, 2, 3\}$ 有序
 $\{2, 3, 1\}$ 有序
 $\{2, 3, 1, 4\}$ 有序

$VDM_{p(cab)} = \frac{\sum_{i=1}^n \mu_{ia} \mu_{ib}}{\mu_{ia} \mu_{ib}}$
 μ_{ia} 表示在属性 i 上取值为 a 的个数, μ_{ia} 表示第 i 个样本簇中属性 i 上取值为 a 的样本数, 为簇数, 这里指的是 a, b 距离

有 n_c 个有序, $n - n_c$ 个无序, 含有序属性排在前面
 $Minkov D_Mp(x_i, x_j) = \left(\sum_{i=1}^{n_c} |x_{iu} - x_{ju}|^p + \sum_{u=n_c+1}^n VDM_p(x_{iu}, x_{ju}) \right)^{\frac{1}{p}}$
还可以加权距离, 用 w

注意: 我们是用距离定义相似度, 然而用于相似度度量的距离有时可以不满足直连性, 此目标称为非度量距离

$d=2 \rightarrow 9 \leftarrow d=2$
 $2+2 < 8$
 $9 \leftarrow d=8 \rightarrow 9$

原型聚类

① K 均值算法

$E = \sum_{i=1}^m \|x_i - \mu_i\|^2$ 最小化 E (NPD 法)
 $\mu_i = \frac{1}{|C_i|} \sum_{x \in C_i} x$ 是簇 C_i 的均值向量
贪心策略:
输入: 样本集 $D = \{x_1, x_2, \dots, x_m\}$
聚类数 k
过程: 从 D 中选 k 个初始 $\mu_1, \dots, \mu_k$
repeat:
 $C_i = \emptyset, i \in \{1, \dots, k\}$
 for $j=1, 2, \dots, m$ do:
 算 $d_j = \|x_j - \mu_i\|^2$
 $\lambda_j = \arg \min_{i \in \{1, \dots, k\}} d_{ji}$
 $C_{\lambda_j} = C_{\lambda_j} \cup \{x_j\}$
 end for // 将所有的样本分入簇中
 for $i=1, 2, \dots, k$ do:
 计算新均值向量: $\mu_i' = \frac{1}{|C_i|} \sum_{x \in C_i} x$
 if $\mu_i \neq \mu_i'$ then:
 $\mu_i = \mu_i'$
 end if
 end for
until 当前均值向量均未更新
输出: $C = \{C_1, \dots, C_k\}$

② 学习向量量化 (LVQ)

先搞清楚 why? $\therefore$ K-means 每次选一个样本都需要加在样本算 $dist$ 开销太多, 我们想, 只需找到几个代表点, 距离就可以了, 这 n 个代表点就是原型向量
 $\{p_1, \dots, p_q\}$ 都是 n 维向量, 每个向量对应的类别为 $\{t_1, t_2, \dots, t_q\}$
输入: 样本集 $D = \{x_1, x_2, \dots, x_m\}$, 原型向量 $\{p_1, \dots, p_q\}$, 原型类别 $\{t_1, \dots, t_q\}$
学习率 $\eta \in (0, 1)$
过程:
1. 初始化 q 个原型向量 $\{p_1, \dots, p_q\}$
2. repeat:
 从样本集 D 中随机选取样本 (x_i, y_i)
 计算 $d_{ij} = \|x_i - p_j\|^2$
 $j^* = \arg \min_{j \in \{1, \dots, q\}} d_{ij}$ k -means 没有
 if $y_i = t_{j^*}$ then:
 $p_{j^*} = p_{j^*} + \eta (x_i - p_{j^*})$
 else
 $p_{j^*} = p_{j^*} + \eta (p_{j^*} - x_i)$ (Voronoi 划分)
 end if
 $p_{j^*}^* = p_{j^*}$ (存储备份)
until 满足停止条件 (一般区域数为 R)
输出: $\{p_1, \dots, p_q\}$

③ 高斯混合聚类

多维向量高斯概率密度:
 $P(x) = \frac{1}{(2\pi)^{\frac{n}{2}} |S|} e^{-\frac{1}{2}(x-\mu)^T S^{-1}(x-\mu)}$
 S 为 $n \times n$ 协方差矩阵, μ 为均值
 $P(x|\mu, S) = \frac{1}{|S|} d_i \cdot P(x|\mu_i, S_i)$
 d_i 为选择第 i 个混合成分的概率, 然后根据被选中的混合成分的概率密度函数进行采样, 从而生成相应的样本
 $D = \{x_1, \dots, x_m\}$ 由上述过程生成
 $z_i \in \{1, 2, \dots, k\}$ 表示 x_i 的高斯混合成分
 $P(z_j=i) = d_i, z_j$ 的后验概率
 $P_m(z_j=i) = \frac{P_m(x_j=i) \cdot P_m(x_j|z_j=i)}{\sum_{i=1}^k P_m(x_j=i) \cdot P_m(x_j|z_j=i)}$
 $P_m(x_j=i) = \frac{d_i \cdot P(x_j|\mu_i, S_i)}{\sum_{i=1}^k d_i \cdot P(x_j|\mu_i, S_i)}$
给出了 x_i 由哪个高斯成分生成的概率, 记为 y_i
 $\lambda_j = \arg \max_{i \in \{1, \dots, k\}} y_i$

利用 EM 算法更新 $\{\mu_i, S_i, z_i\}$

输入: 样本集 $D = \{x_1, x_2, \dots, x_m\}$
高斯混合成分个数 k
过程:
1. 初始化高 μ_i, S_i, z_i
repeat
 for $j=1, 2, \dots, m$ do
 计算 $y_j = P_m(z_j=i|x_j)$ ($i \in \{1, \dots, k\}$)
 end for
 for $i=1, \dots, k$ do
 计算 $\mu_i' = \frac{\sum_{j=1}^m y_{ji} x_j}{\sum_{j=1}^m y_{ji}}$
 $S_i' = \frac{\sum_{j=1}^m y_{ji} (x_j - \mu_i')(x_j - \mu_i')^T}{\sum_{j=1}^m y_{ji}}$
 $d_i' = \frac{\sum_{j=1}^m y_{ji}}{\sum_{j=1}^m y_{ji}}$ (归一化)
 end for
 更新 $C(\mu_i, S_i, z_i) = \{x_j | y_{ji} > 0\}$
until 满足停止条件
 $C_i = \emptyset, i \in \{1, \dots, k\}$
for $j=1, \dots, m$ do
 $\lambda_j = \arg \max_{i \in \{1, \dots, k\}} y_{ji}$
 $C_{\lambda_j} = C_{\lambda_j} \cup \{x_j\}$
end for
输出: $C = \{C_1, \dots, C_k\}$

密度聚类

之前的算法都倾向于生成球形簇, 而现实中可能是“半月型”或“长条型”, 前面算法就失败了

2. 新的算法者倾向于生成球形簇, 而现实中可能是“半月型”或“长条型”, 前面算法就失败了

密度聚类从样本密度的角度考虑样本间的可连接性

可以基于可连接样本不断扩展聚类簇

一些术语与定义

相关参数: $(\epsilon, minpts)$
① 核心对象: 样本 A 的 ϵ 范围内至少有 $minpts$ 个点, 则 A 为核心对象
② 密度可达: $A, P_1, P_2, \dots, P_k$ 可由 A 直达, P_2 可由 P_1 直达, ..., 则 B 可由 A 密度可达
③ 密度相连: O 为核心对象, A 可由 O 密度可达, B 可由 O 密度可达, 则 A 与 B 密度相连

关键算法

输入: 样本集 $D = \{x_1, \dots, x_m\}$
相关参数 $(\epsilon, minpts)$
过程:
初始化核心对象集合 $\Omega = \emptyset$
for $j=1, 2, \dots, m$ do
 if $|N_\epsilon(x_j)| \geq minpts$ then:
 $\Omega = \Omega \cup \{x_j\}$
 end if
end for // 确定性是核心对象
 $k=0$, 簇数 $\Gamma = D$, 未访问样本集
while $\Omega \neq \emptyset$ do
 $\Gamma_{old} = \Gamma$ // 记录当前簇为 Γ
 while $\Omega \neq \emptyset$ do
 取出 Ω 中样本 q
 if $|N_\epsilon(q)| \geq minpts$ then:
 $\Delta = N_\epsilon(q) \cap \Gamma$ (访问过的簇成员)
 将 Δ 加入 Ω
 $\Gamma = \Gamma \cup \Delta$
 end if
 end while
 $k=k+1, C_k = \Gamma_{old} \cap \Gamma$
 $\Omega = \Omega \setminus C_k$ (访问过的簇成员)
end while
输出: $C = \{C_1, C_2, \dots, C_k\}$

层次聚类

树形聚类结构

循环合并最近的两个聚类簇进行合并

类间距离:

① 最小距离: $d_{min}(C_i, C_j) = \min_{x \in C_i, y \in C_j} dist(x, y)$
② 最大距离 d_{max} 用 g
③ 平均距离: $\frac{1}{|C_i||C_j|} \sum_{x \in C_i} \sum_{y \in C_j} dist(x, y)$

关键算法

输入: 样本集 $D = \{x_1, x_2, \dots, x_m\}$
聚类距离度量函数 d
聚类簇数 k
过程:
for $j=1, 2, \dots, m$ do
 $C_j = \{x_j\}$
end for // 初始化
for $i=1, \dots, m$ do
 for $j=i+1, \dots, m$ do
 $M(i, j) = d(C_i, C_j)$
 $M(j, i) = M(i, j)$
 end for
end for
设置当前聚类簇数: $q=m$
while $q > k$ do
 找出距离最近的两聚类簇 C_i^* 和 C_j^*
 $C_i^* = C_i^* \cup C_j^*$
 for $j=i^*+1, \dots, q$ do
 将 C_j 重编号为 C_{j-1}
 end for
 删除 M 矩阵第 j^* 行和第 j^* 列
 for $j=1, 2, \dots, q-1$ do:
 $M(C_i^*, j) = d(C_i^*, C_j)$
 $M(j, C_i^*) = M(C_i^*, j)$
 end for
 $q=q-1$
end while
输出: 簇划分 $C = \{C_1, C_2, \dots, C_k\}$