

K 近邻学习

懒惰学习, 训练时断把样本保存起来, 测试时样本进入后再处理
下面讨论 $1NN$ 在二分类问题上的性能

给定测试样本 x 与近邻样本 z , 此时犯错误概率: $P(\text{error}|x) = \frac{1}{2} P(\text{error}|1-P(\text{error}|x))$
当样本数 $m \rightarrow +\infty$ 时, z 会趋近于 x
则 $P(\text{error}) \approx P(\text{error}|z)$
 $\therefore P(\text{error}|x) \approx 1 - \frac{1}{2} P(\text{error}|x)$
贝叶斯分类器: $R^* = 1 - P(\text{error}|x)$
 $\sum_{i=1}^m P(\text{error}|x) \geq P(\text{error}|x)$
 $\therefore P(\text{error}|x) \leq 1 - P(\text{error}|x)$
 $\leq R^* \cdot \frac{1}{2} P(\text{error}|x)$
 $\geq R^*$
1NN 错误率不超过贝叶斯分类器二倍!

低维嵌入

涉及 MDS 算法, 降维后的新距离 $\|z_i - z_j\| = D_{ij}$ (等于老距离)

令 $B = Z^T Z \in R^{m \times m}$, B 为降维后内积矩阵
 $b_{ij} = z_i^T z_j$; $\text{dist}_{ij}^2 = \|z_i - z_j\|^2 = z_i^T z_i + z_j^T z_j - 2 z_i^T z_j$
对降维后的 Z 中心化, 即 $\sum_{i=1}^m z_i = 0$
 $\sum_{i=1}^m b_{ij} = \sum_{i=1}^m z_i^T \cdot z_j = 0 \Rightarrow$ 任意一行和为 0
 $\sum_{j=1}^m b_{ij} = z_i^T (\sum_{j=1}^m z_j) = 0 \Rightarrow$ 任意一列和为 0
 $\sum_{i,j=1}^m b_{ij} = 0 \Rightarrow$ 所有元素和为 0

点到点的距离 dist $\sum_{i=1}^m \text{dist}_{ij} = m b_{ii} + \text{tr}(B) + 0$ 令 $D_{ii} = \frac{1}{m} \sum_{j=1}^m \text{dist}_{ij}$ $\therefore b_{ii} = D_{ii} - \frac{1}{m} \text{tr}(B)$	行方向 $b_{ij} = D_{ij} - \frac{1}{m} \text{tr}(B)$	全元素和 $\sum_{i,j=1}^m b_{ij} = m \text{tr}(B) + 0$ 令 $D_{ii} = \frac{1}{m} \sum_{j=1}^m \text{dist}_{ij}$ $\therefore \text{tr}(B) = \sum_{i=1}^m D_{ii}$
--	---	---

通过内积矩阵 B 计算
坐标矩阵 Z

Z 是 $m \times d'$ 的矩阵, B 是 $m \times m$ 的矩阵
 B 是实对称半正定矩阵, 对称矩阵, 这里证明半正定.
 $V^T B V = V^T (Z Z^T) V = (Z^T V)^T (Z^T V) = U^T U$
则原式 $= U^T U \geq 0$ $\therefore B$ 半正定对称
对 B 进行特征值分解:
 $B = V \Lambda V^T$ (Λ 为特征值对角阵)
(V 为特征向量矩阵)
为何此处 V^T 未了, 不应该是右乘 V^T 吗? 这是因为 $V^T = V^{-1}$:
 $\begin{cases} Bx = \lambda x \\ By = \lambda y \end{cases} \Rightarrow \begin{cases} x^T B y = x^T \lambda y = \lambda x^T y \\ (x^T B) y = (B x)^T y = \lambda x^T y \end{cases}$
 $\Rightarrow \lambda_1 x^T y = \lambda_2 x^T y \xrightarrow{\text{非零}} \therefore x^T y = 0 \therefore V^T V = I$
(默认每个特征向量长度 $\|x\| = 1$ 的)
 $B = V \Lambda V^T \Rightarrow V^T = (V \Lambda V^T)^T = V \Lambda^T V^T$
 $\therefore Z = V \Lambda^{\frac{1}{2}}$ (若 Z 是 $d' \times m$ 矩阵则 $B = Z^T Z$, $Z = \Lambda^{\frac{1}{2}} V^T$)
此时 Z 仍是 $m \times m$, 我们对于 Λ 的特征值排序 $\lambda_1 > \lambda_2 > \dots$
为保留前 d' 个特征值, 则 V 变成 $m \times d'$, Λ 变成 $d' \times d'$
 $Z = V \Lambda^{\frac{1}{2}}$ (同样若 Z 是 $d' \times m$ 则 $Z = \Lambda^{\frac{1}{2}} V^T$)

主成分分析 (PCA)

在正交属性空间中的样本点, 也可用一个超平面对所有样本进行表达
在这个超平面上的样本点, 到该超平面的距离都是 0

- ① 最近重构性: 样本点到这个超平面的距离都是 0
- ② 最大可分性: 样本点在这个超平面上的投影能尽可能分开

样本已中心化: $\sum x_i = 0$; 投影后新坐标为 $\{w_1, w_2, \dots, w_d\}$, 其中 w_i 是标准正交基向量

若每新坐标系中部分坐标, 同时维度降低到 d' , $d' < d$.

则 $x_i \rightarrow z_i = (z_{i1}, z_{i2}, \dots, z_{id'})$; 其中 $z_{ij} = w_j^T x_i$ 是 x_i 在低维坐标系第 j 维的坐标

若基于 z_i 来拟合 x_i , 则 $\hat{x}_i = \sum_{j=1}^{d'} z_{ij} w_j \Rightarrow$ 关于 z 的拟合 $\Rightarrow$ 关于 z 的拟合

最近重构性

最大可分性

$\sum_{i=1}^m \left\| \sum_{j=1}^{d'} z_{ij} w_j - x_i \right\|_2^2 = \sum_{i=1}^m \left\| W z_i - x_i \right\|_2^2 = \sum_{i=1}^m \left[(W z_i)^T (W z_i) - 2 z_i^T W^T x_i + x_i^T x_i \right]$
 $= \sum_{i=1}^m \left[z_i^T W W^T z_i - 2 z_i^T W^T x_i + \text{const} \right]$
 $= \sum_{i=1}^m z_i^T z_i - 2 \sum_{i=1}^m z_i^T W^T x_i + \text{const}$
 $= - \sum_{i=1}^m z_i^T z_i + \text{const}$
 $= - \sum_{i=1}^m (W^T x_i)^T (W^T x_i) + \text{const}$
 $= - \sum_{i=1}^m x_i^T W W^T x_i + \text{const}$
要使 $\sum_{i=1}^m x_i^T W W^T x_i$ 最大, 则 $\sum_{i=1}^m x_i^T W W^T x_i$ 最大

由于数据样本已中心化, 因此 $\text{Var} = \sum_{i=1}^m (W^T x_i)^2$
 $\text{Var} = \sum_{i=1}^m (W^T x_i) (x_i^T W) = W^T \left(\sum_{i=1}^m x_i x_i^T \right) W = W^T \Sigma X^T W$
这里的 Σ 是 $d \times d$ 的, 和之前的 Σ (mod) 不同
目标也是 $\max W^T \Sigma X^T W$
s.t. $W^T W = I$

拉格朗日乘子法优化:
 $L(W, \lambda) = W^T \Sigma X^T W - \lambda (W^T W - I)$
 $\frac{\partial L(W, \lambda)}{\partial W} = 2 \Sigma X^T W - 2 \lambda W = 0$
 $\therefore \Sigma X^T W = \lambda W \Rightarrow \Sigma X^T$
 $\therefore \text{Var} = W^T \Sigma X^T W = W^T W \lambda = \lambda$

再求特征值即可 ΣX^T 会求出 d' 个特征值 $\lambda_1, \dots, \lambda_{d'}$
排序: $\lambda_1 > \lambda_2 > \dots > \lambda_{d'}$
若 λ_i 为总方差, $\eta = \frac{\sum_{i=1}^{d'} \lambda_i}{\sum_{i=1}^d \lambda_i}$ 当 $\eta > 95\%$ 时在面就砍掉

Var 是对角矩阵代表 PCA 已经去除了共线性.

核化线性降维

先升维再去找超平面降维

$\text{Var} = \Sigma X^T \Rightarrow C = \phi(x) \phi(x^T)$
① 高维空间的投影轴 w , 必然可以被这 m 个样本的映射 $\phi(x_i)$ 线性表出
 $\vec{w} = \sum_{i=1}^m \alpha_i \phi(x_i) = \phi(x) \alpha$
② PCA 结论:
 $C \phi(\vec{w}) = \lambda \vec{w}$
 $[\phi(x) \phi(x^T)] \vec{w} = \lambda \vec{w}$
 $[\phi(x) \phi(x^T)] [\phi(x) \alpha] = \lambda \phi(x) \alpha$
左乘 $\phi(x)^T$
 $\phi(x)^T \phi(x) \alpha = \lambda \alpha$
 $K \alpha = \lambda \alpha$

流形学习

去解决区近距离面对曲面产生的错误信息.
两种方式

等度量映射 (Isomap) (时间开销 $O(N^3)$)

LLE (局部线性嵌入)

[全局]

[局部]

核心思想: 将曲线距离切割成无卷绕的欧氏距离去近似
输入: 样本集 $D = \{x_1, \dots, x_m\}$
近邻索引 k_1, k_2
降维空间维数 d'
过程:
for $i = 1 \dots m$ do
 确定 x_i 与 k_1 近邻
 x_i 与 k_2 近邻的距离设置成
 欧氏距离, 与其他距离设置成
 无穷大
end for
调用 Dijkstra 算法求最短路径
 $\text{dist}(x_i, x_j)$
将 $\text{dist}(x_i, x_j)$ 作为 MDS 输入
return MDS 算法输出
输出: 样本集 D 在降维空间的
投影 $Z = \{z_1, z_2, \dots, z_m\}$

不关心数据全局特征, 只在意样本与邻居的关系, 只要样本与邻居的关系能无损地投影过去, 全局自然也“等距”了.
① 设样本 x_i 有 k_1 个邻居
则 $x_i \approx w_{i1} x_{i1} + w_{i2} x_{i2} + w_{i3} x_{i3}$
通过最小化 $\|x_i - w_{i1} x_{i1} - w_{i2} x_{i2} - w_{i3} x_{i3}\|^2$ 来求出权重矩阵 W
② 在降维空间中, 邻居关系不变, 则需 $\min \sum_{i=1}^m \|z_i - \sum_{j=1}^m w_{ij} z_j\|^2$
 w_{ij} 已知, 需要求 z_i
 $\|A\|_F^2 = \text{tr}(A A^T)$ $\|A\|_F^2$ 为每个元素平方和
 $E = \|Z - Z W\|_F^2$ Z 为 $d' \times m$
 $= \text{tr}[(Z - Z W)(Z - Z W)^T] = \text{tr}(Z(I - W)^T (I - W) Z^T)$
 $= \text{tr}(Z M Z^T)$
s.t. $Z Z^T = I$ (内积归一化, 归为一个点)
 M 最小的 d' 个特征值对应的特征向量组成的矩阵即为 Z^T .

补充相关计算:
 $\sum_{i,j=1}^m w_{ij} z_j = E = \sum_{i,j=1}^m w_{ij} (x_i - x_j) \sum_{i,j=1}^m w_{ij} z_j$
令 $Z_i = [x_i - x_1, \dots, x_i - x_k]$
(每一列是一个 $x_i - x_j$) (这个 Z 和前面的 Z 无关)
 $E = \|Z_i W_i\|_F^2 = (Z_i W_i)^T (Z_i W_i)$
 $= W_i^T Z_i^T Z_i W_i$
 C 是 $k \times k$ 的矩阵
目标函数: $\min w_i^T C w_i$
s.t. $I^T W_i = I$ (I 为全 1 的列向量)
拉格朗日得: $w_i = \frac{1}{I^T C I} C I$
则 $I^T (C I) = I$ 即 $C = I I^T I$
 $\therefore W_i = \frac{C I}{I^T C I}$, 这跟前面 $C = I I^T I$

$\text{tr}(Z M Z^T) = \text{tr}(A Z Z^T) = \text{tr}(A)$
 $L(Z, \lambda) = \text{tr}(Z M Z^T) - \text{tr}(A Z Z^T)$
求得 $Z M = \lambda Z \Rightarrow M Z^T = Z^T \Lambda$
 $\min \text{tr}(Z M Z^T) \Rightarrow \min \text{tr}(A)$ (特征值归一化)

度量学习

降维的本质是在改变距离的定义, 区近距离为什么不行?

引入马氏距离.

$\text{dist}_{ij}^2 = (x_i - x_j)^T M (x_i - x_j)$

M : ① 对角线上, $m_{11}, m_{22}, \dots$ 是每个特征的权重

② 交叉项上, 是表示不同特征间的相互影响.

③ 半正定且对称, $M = P^T P$ (P 是 $d \times d$ 的矩阵)

$\text{dist}_{ij}^2 = (x_i - x_j)^T P^T P (x_i - x_j) = [P(x_i - x_j)]^T [P(x_i - x_j)]$
新维度的坐标差

M 如何计算?

两组约束: y 与 z 必须连接
 $\min \sum_{(x_i, x_j) \in \mathcal{R}} \|x_i - x_j\|_M^2$
s.t. $\sum_{(x_i, x_j) \in \mathcal{C}} \|x_i - x_j\|_M^2 \geq 1$
 M 半正定, 对称
优化过程略